Documento de Diseño: NERticleS - Pipeline de Análisis Inteligente

1. Introducción y Contexto

El cliente MediaGroup LATAM requiere un pipeline automático y auditable para procesar artículos periodísticos. El sistema debe ingerir artículos, analizarlos con LLMs, extraer entidades (NER), generar resúmenes SEO y clasificarlos por sentimiento, sin bloquear al cliente y controlando los costos operativos.

2. Arquitectura de la Solución

Se diseñó un pipeline asíncrono de 7 etapas alojado en Google Cloud Platform (GCP):

Ingest: Webhook en FastAPI (/webhook/articles) que recibe el artículo y responde en <200ms usando BackgroundTasks.

Validar: Reglas de negocio (mínimo 50 palabras, filtro anti-spam).

Limpiar: Eliminación de HTML y normalización de texto.

Analizar: Llamada al LLM (Google AI Studio / Gemini).

Enriquecer: Extracción de entidades y análisis de sentimiento.

Resumen SEO: Truncado y validación a máximo 160 caracteres.

Exportar: Persistencia en base de datos (SQLite en desarrollo, PostgreSQL en producción).

3. Decisiones de Diseño y Alternativas Descartadas

Framework Web (FastAPI vs Flask): Se eligió FastAPI por su soporte nativo para asincronía y su integración con Pydantic para validación de esquemas.

Procesamiento Asíncrono: Se descartó usar Celery/Redis por la complejidad de infraestructura. Se usó BackgroundTasks de FastAPI, suficiente para este MVP, logrando que el webhook responda en milisegundos.

Proveedor LLM (AI Studio vs Vertex AI): Inicialmente se intentó usar Vertex AI. Sin embargo, el proyecto presentó restricciones de acceso (errores 403/404 por políticas de Google Cloud para nuevos proyectos). Como contingencia, se migró a Google AI Studio, la API oficial de Gemini, que ofrece la misma calidad de modelo sin la complejidad de IAM ni las restricciones de aprovisionamiento.

Resiliencia (Fallback): Se implementó un patrón de Fallback automático. Si AI Studio falla o el costo estimado supera el umbral (COST_THRESHOLD), el sistema conmuta a Ollama (Llama 3.2) local. Esto asegura que el pipeline nunca se detenga por caídas del proveedor o límites de cuota.

4. Seguridad e Infraestructura (Modalidad GCP)

Autenticación: Uso de JWT (JSON Web Tokens) para proteger el webhook.

Rate Limiting: Implementado con slowapi (10 req/min) para prevenir ataques DDoS y controlar el gasto en tokens.

Despliegue: Uso de Docker y Cloud Run.

Secret Manager: Las credenciales (GEMINI_API_KEY) no están en el código, sino inyectadas como variables de entorno desde Secret Manager.

Base de Datos en Nube: Uso de Cloud SQL (PostgreSQL) conectado a Cloud Run mediante el socket Unix (/cloudsql/...).

5. Costos Proyectados

Google AI Studio (Gemini): El nivel gratuito cubre la demanda inicial. Costo estimado por artículo: ~$0.0001 USD.

Ollama Local: $0 USD (solo costo de cómputo local).

Cloud Run: Escala a cero. Costo estimado para 100 artículos diarios: <$1 USD/mes.

Cloud SQL: Instancia db-f1-micro, costo aproximado de $10 USD/mes (puede variar).